# Фреймворк обучения LLM

Елена Кантонистова

# План

- Recap базового обучения BERT и GPT
- Attention в матричном виде
- Фреймворк обучения генеративных чат-ботов
- Prompt-engineering и prompt-tuning

# Recap базового обучения GPT и BERT

# Как модели учатся понимать язык?

# Обучение на текстах: задача 1

Для обучения используется простой прием: часть слов мас[redacted]ется. Задача нейросети предположить, какие слова б[redacted]ропущены. При этом нейросеть обучается на всех доступных текстах. Это огромнейший[redacted]ив данных.

# Обучение на текстах: задача 1

Для обучения используется простой прием: часть слов маскируется. Задача нейросети предположить, какие слова были пропущены. При этом нейросеть обучается на всех доступных текстах. Это огромнейший массив данных.

# Обучение на текстах: задача 2

# Attention!

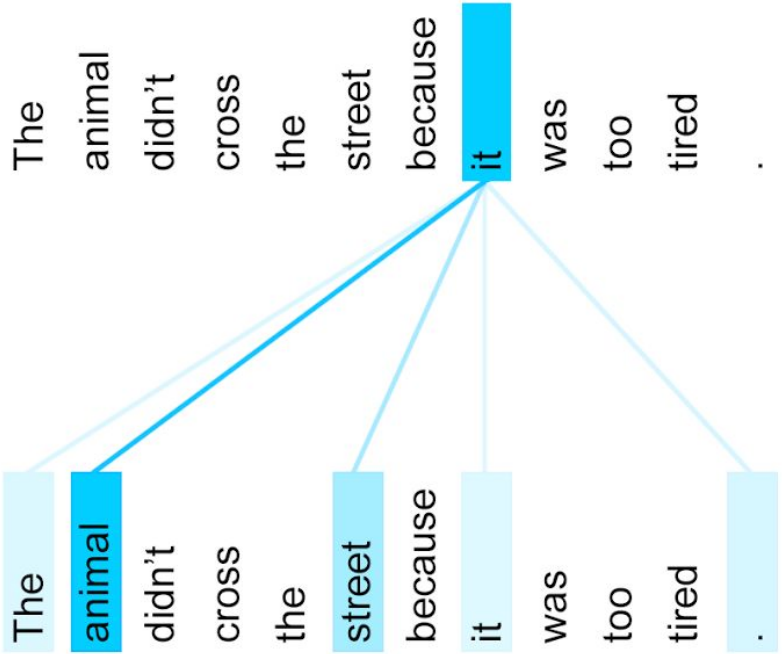
The
animal
didn't
cross
the
street
because
it
was
too
tired
.
The
animal
didn't
cross
the
street
because
it
was
too
tired
.

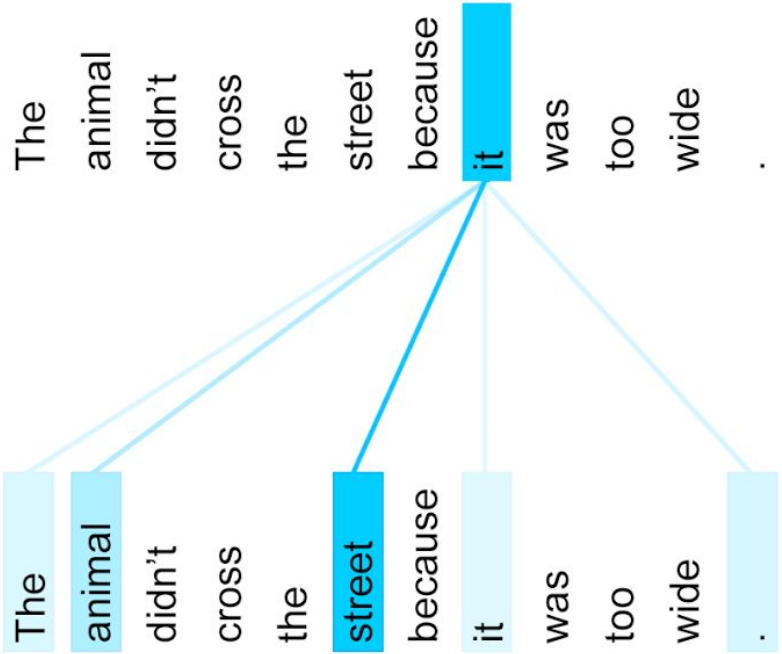
The
animal
didn't
cross
the
street
because
it
was
too
wide
.
The
animal
didn't
cross
the
street
because
it
was
too
wide
.

# BERT (encoder-модель)

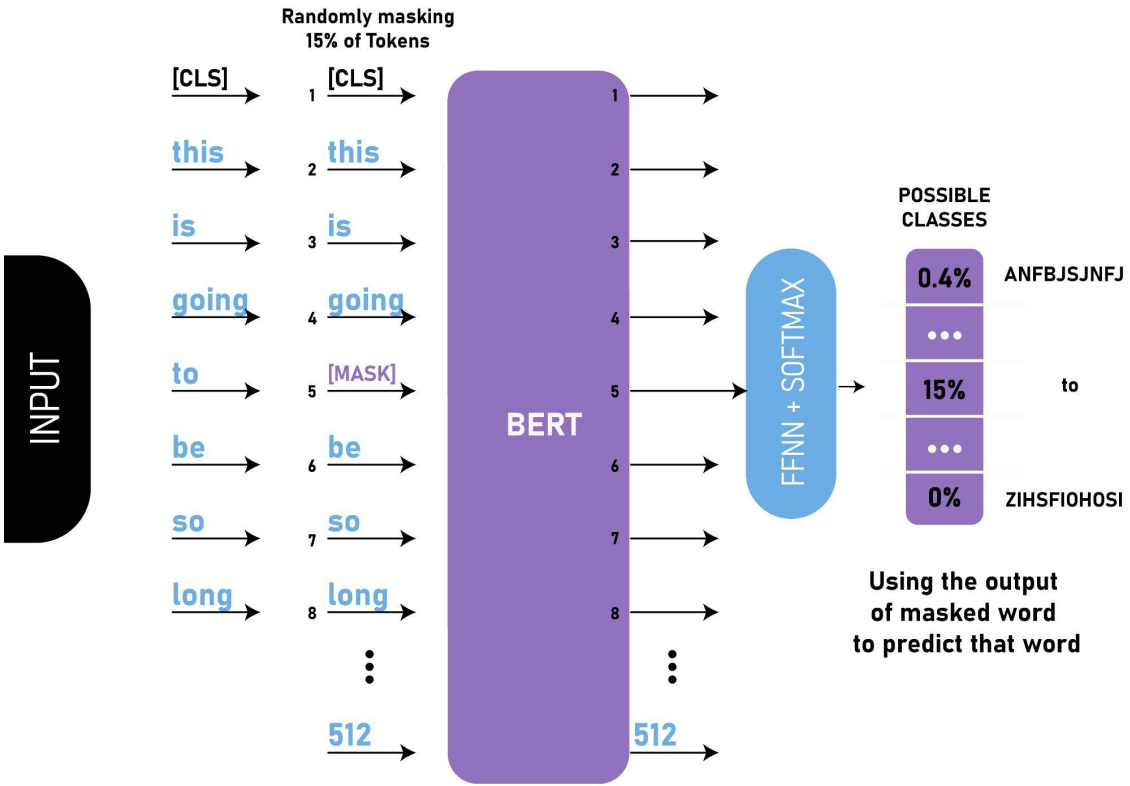

# GPT (decoder-модель)

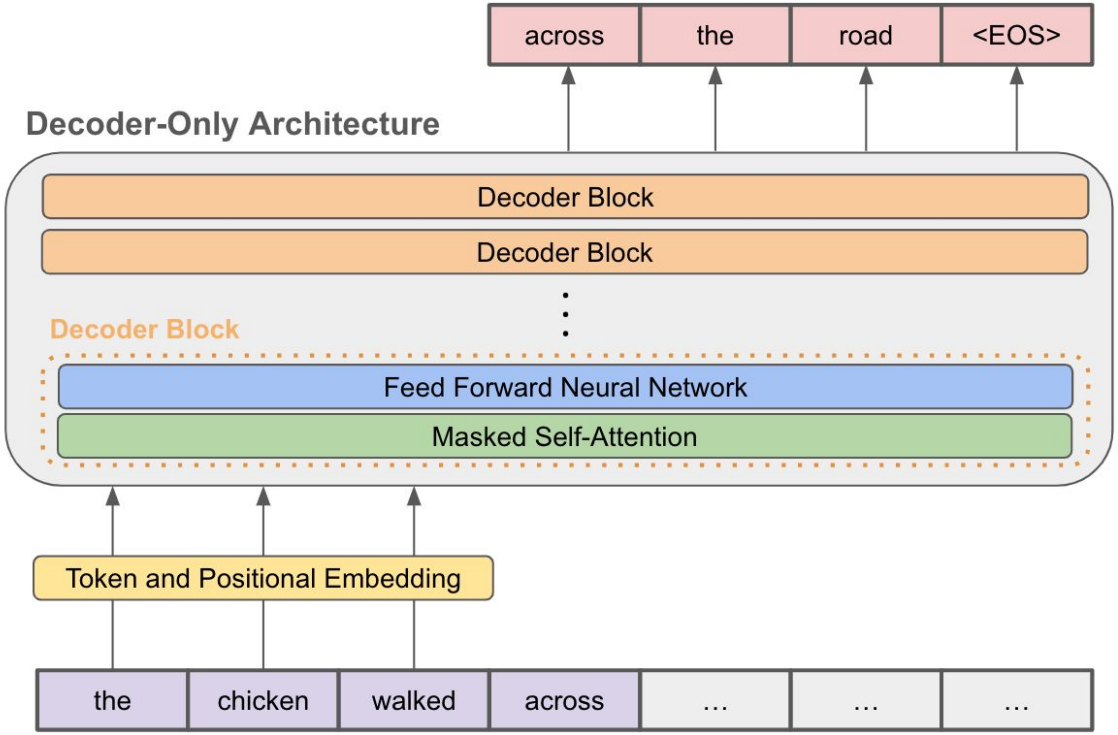

# Attention в матричном виде

# Attention: матричный вид

- На вход подается текст некоторой длины max_length
- Каждый токен закодирован своим id
- При проходе через embedding-слой токен становится вектором фиксированной длины (например, 512) со встроенным знанием позиции

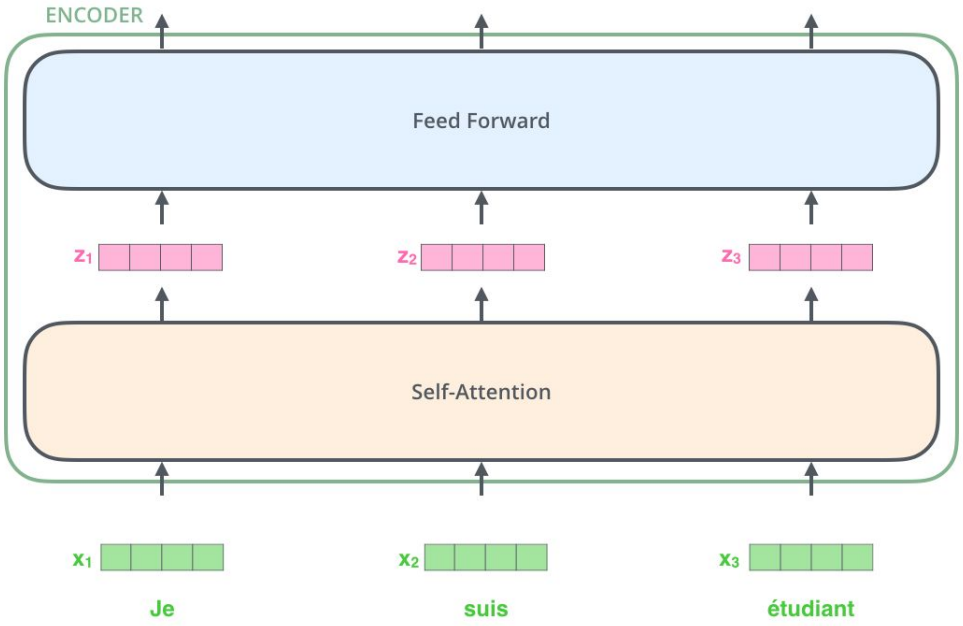

# Позиционное кодирование

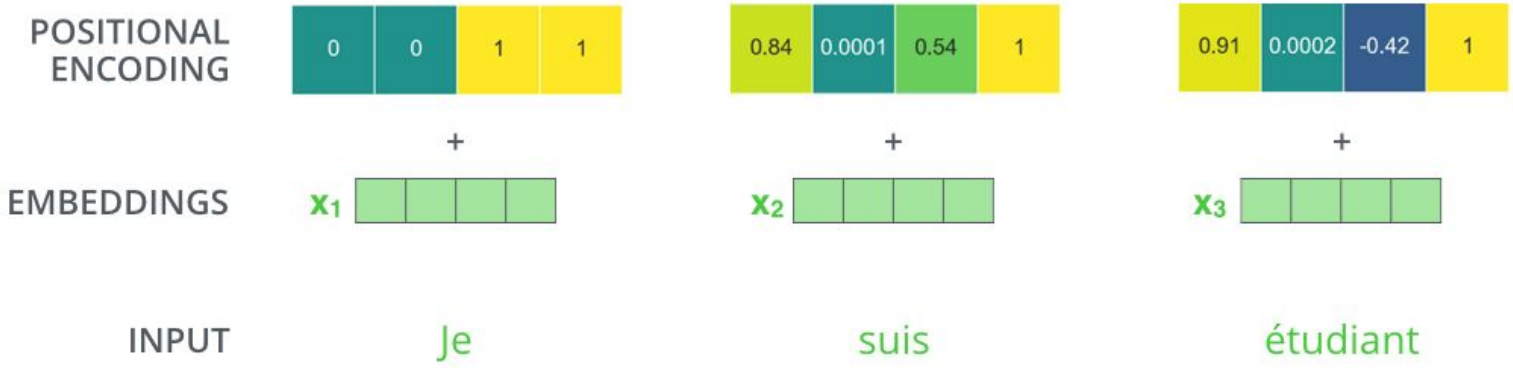


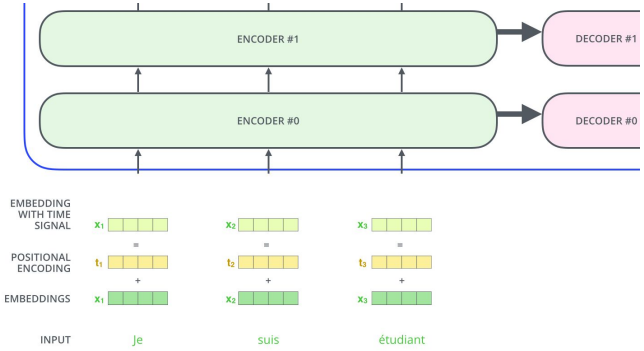

# Attention: матричный вид

- На вход в attention передается вектор-эмбеддинг слова
- Далее он умножается на матрицы Wq, Wk, Wv и получаются векторы q, k, v для каждого токена

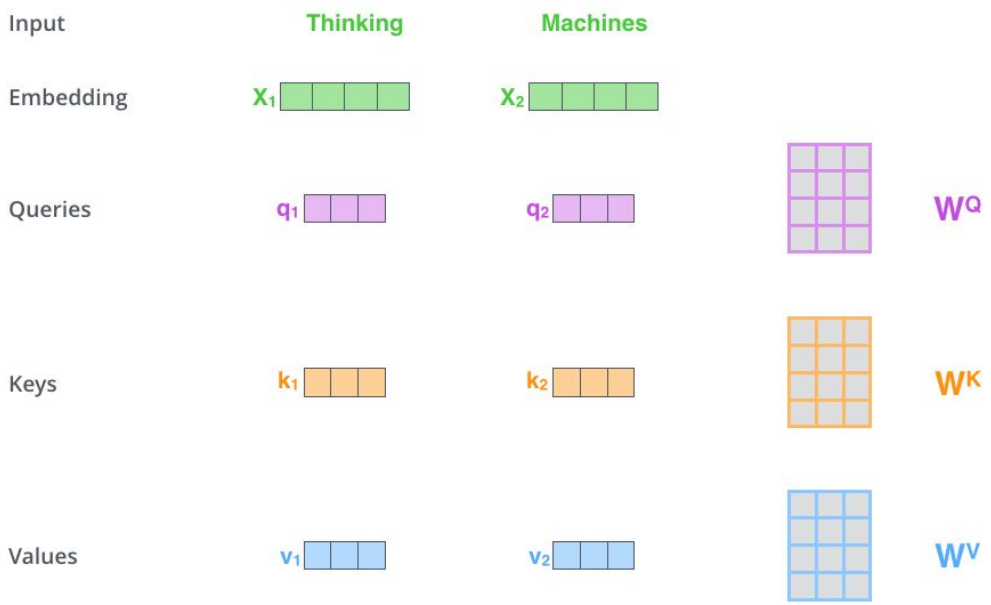

# Attention: матричный вид

- Текст, поданный на вход, можно представить в виде матрицы
- Тогда после прохождения через attention-слой мы получим матрицы Q, K, V, где строк столько, сколько было слов в тексте (сколько было строк в зеленой матрице)

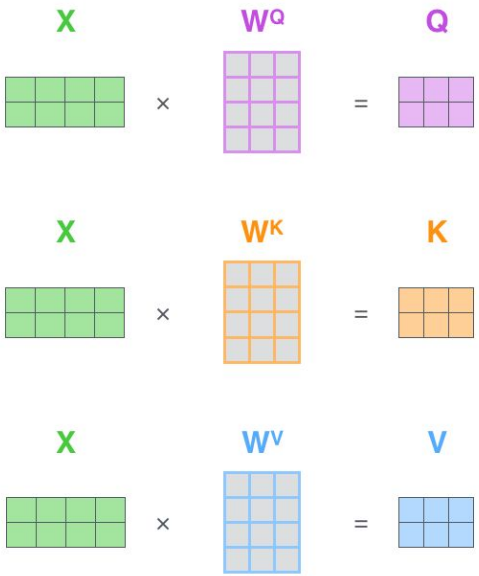

# Attention: матричный вид

- Softmax и дальнейшее умножение на values также можно записать в векторном виде

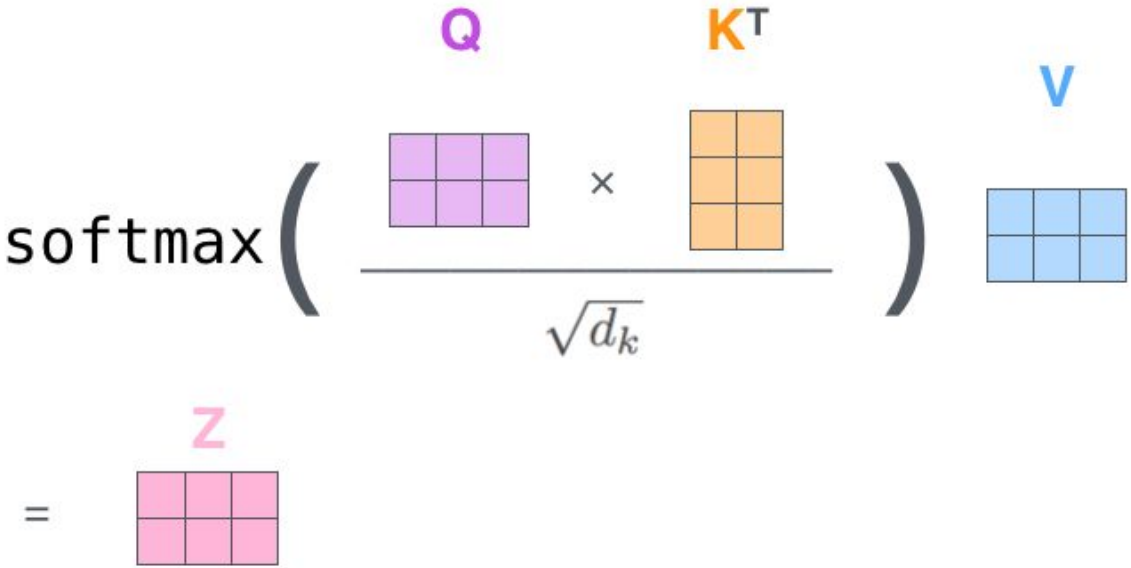

# Attention: матричный вид

- Обычно в attention несколько голов, как это можно представить матрично?

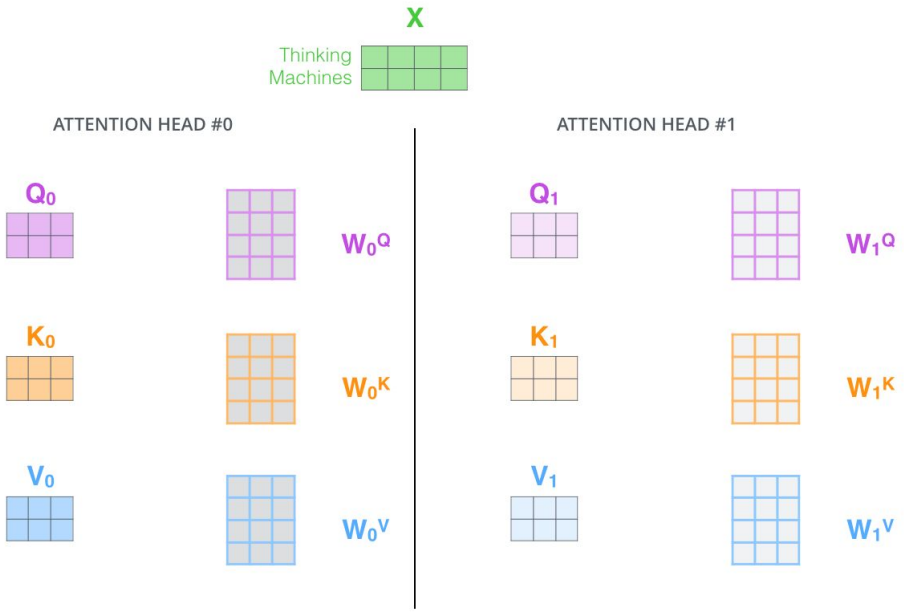

# Attention: матричный вид

- Каждая голова attention выдает вектор внимания для каждого слова в последовательности

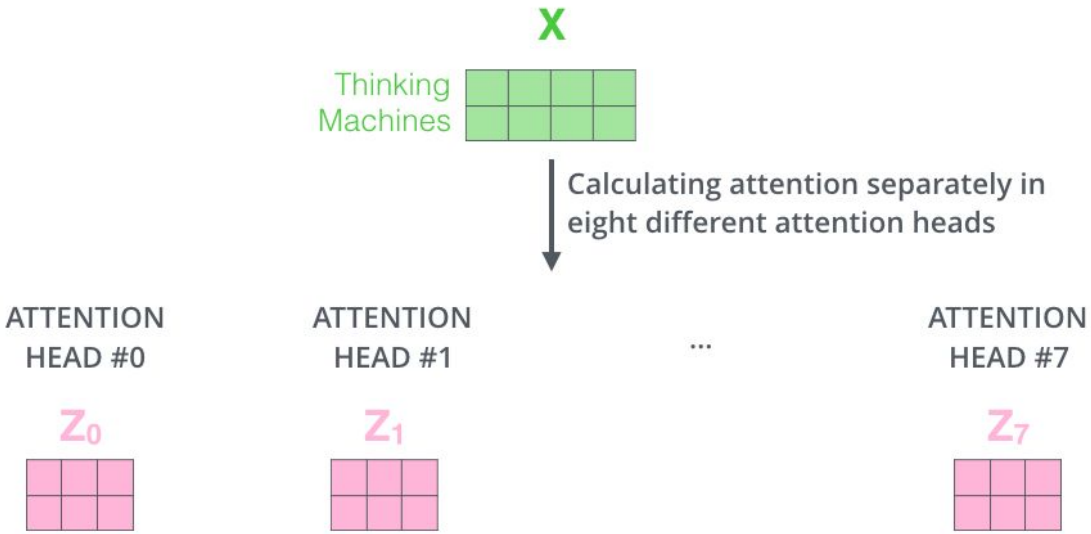

# Attention: матричный вид

- Затем эти векторы (матрицы) конкатенируются и результат умножается на дополнительную матрицу весов W0 - в итоге получается вектор многоголового внимания для каждого слова из последовательности

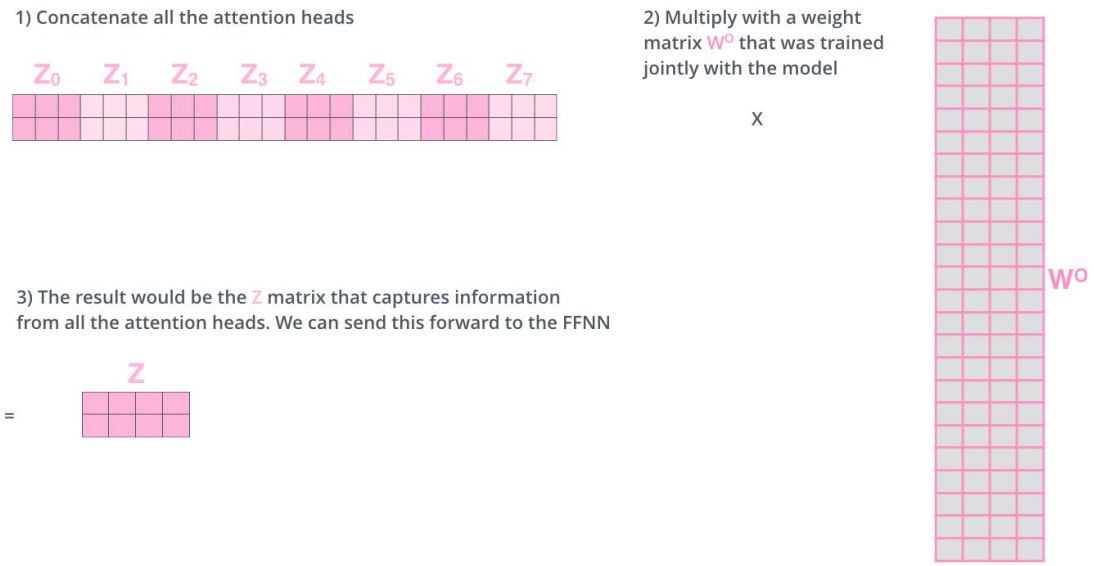

# Attention: матричный вид

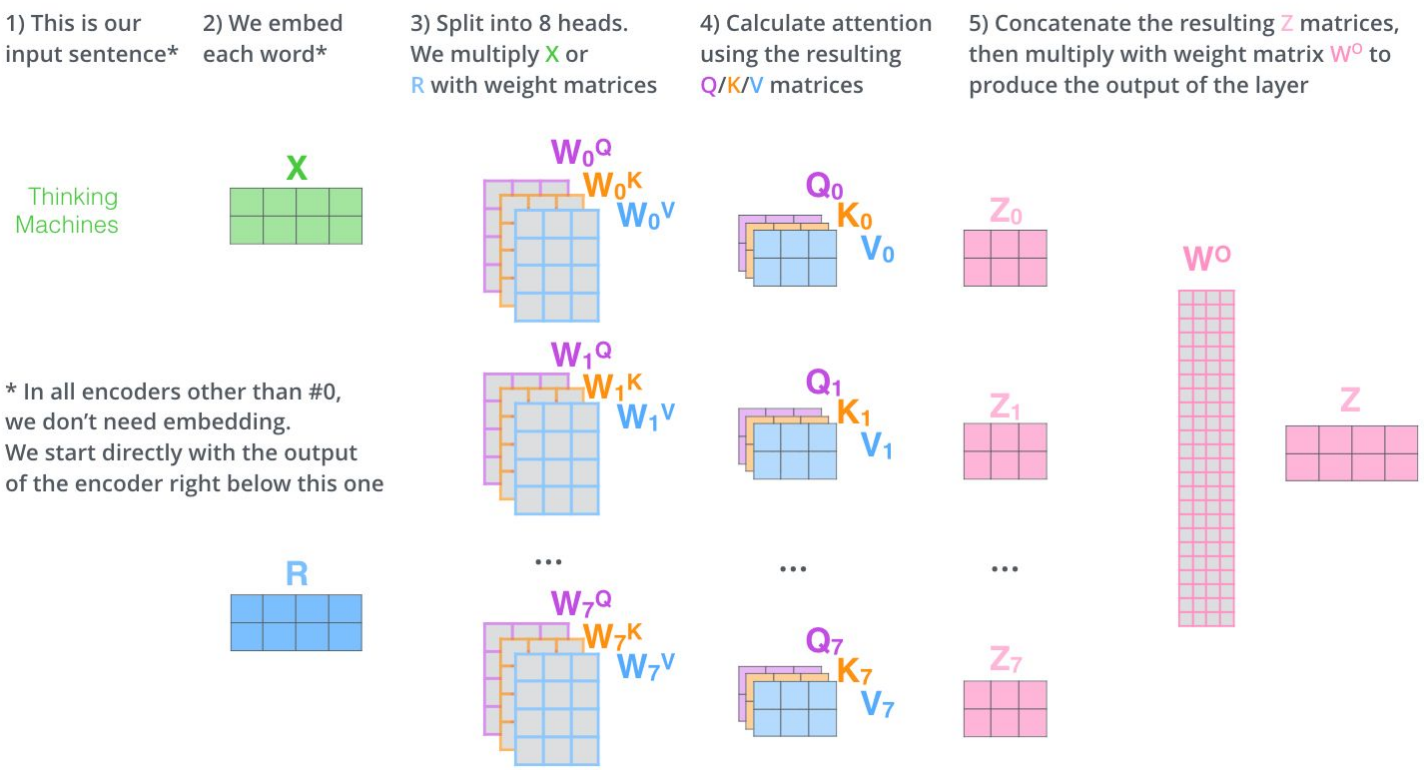

# FFN-слои

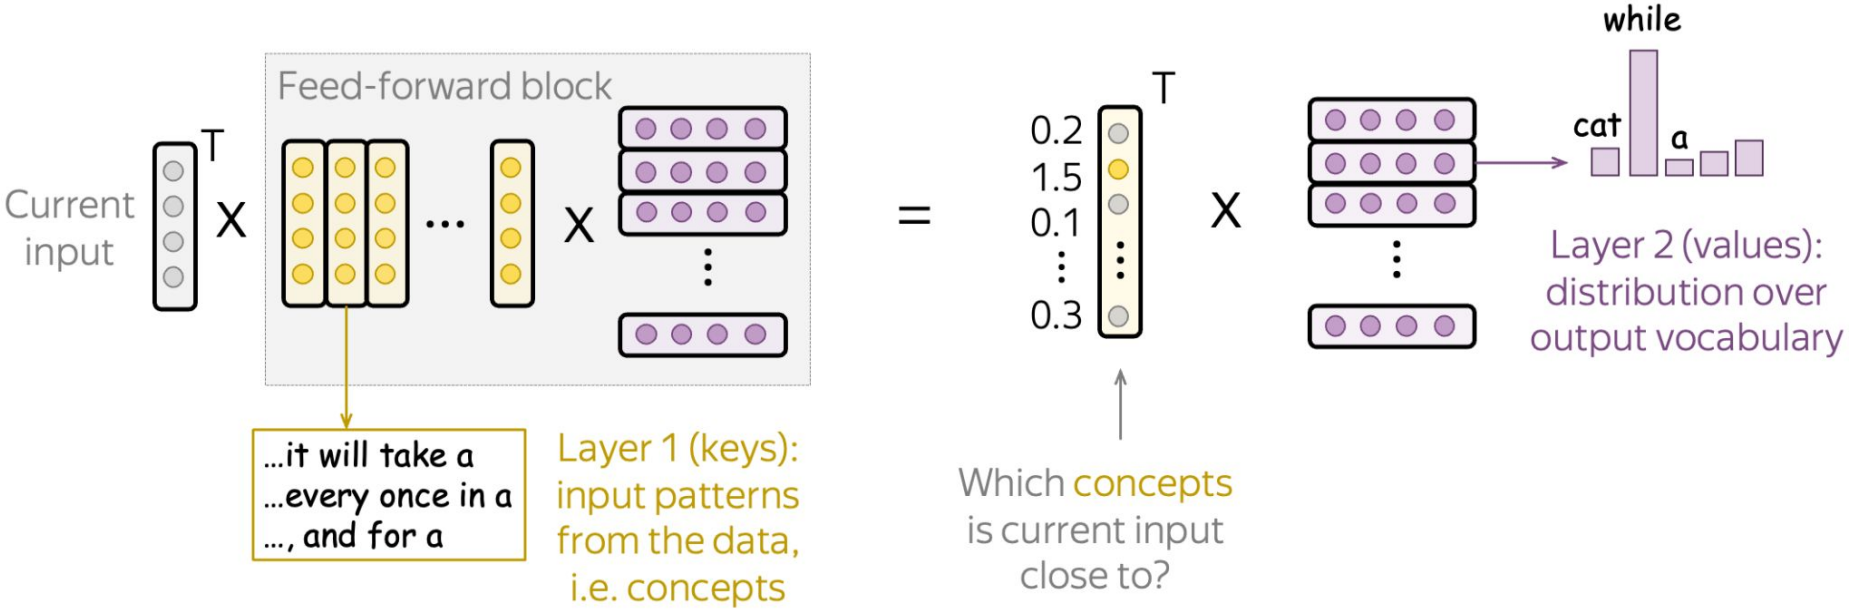
Feed-forward block
Current input
T
X
...
X
=
0.2
1.5
0.1
0.3
T
X
while
cat
a
...it will take a
...every once in a
..., and for a
Layer 1 (keys): input patterns from the data, i.e. concepts
Which concepts is current input close to?
Layer 2 (values): distribution over output vocabulary

# Обозначения

Batch_size - это число токенов в батче. Когда последовательности очень разной длины, то имеет смысл ограничивать батч именно числом токенов, а не количеством примеров.

Как это работает?

- Пусть batch_size=1500, и на вход пришли последовательности длины 600, 500, 400.
- Мы получим тензор размера (3, 600), где все последовательности в батче дополнены паддингом до максимальной длины.
- Далее каждая последовательность - это двумерный тензор размера (600, dim_size), где dim_size - размер эмбеддинга каждого токена

Итого мы имеем трехмерный тензор размера (3, 600, dim_size).

# Обозначения

Seq_length - это максимальная длина входной последовательности. Если последовательность короче - она добивается до seq_length паддингом, а если длиннее - то отбрасывается на этапе обучения, либо разбивается на кусочки

# Влияние числа токенов в батче (batch size)

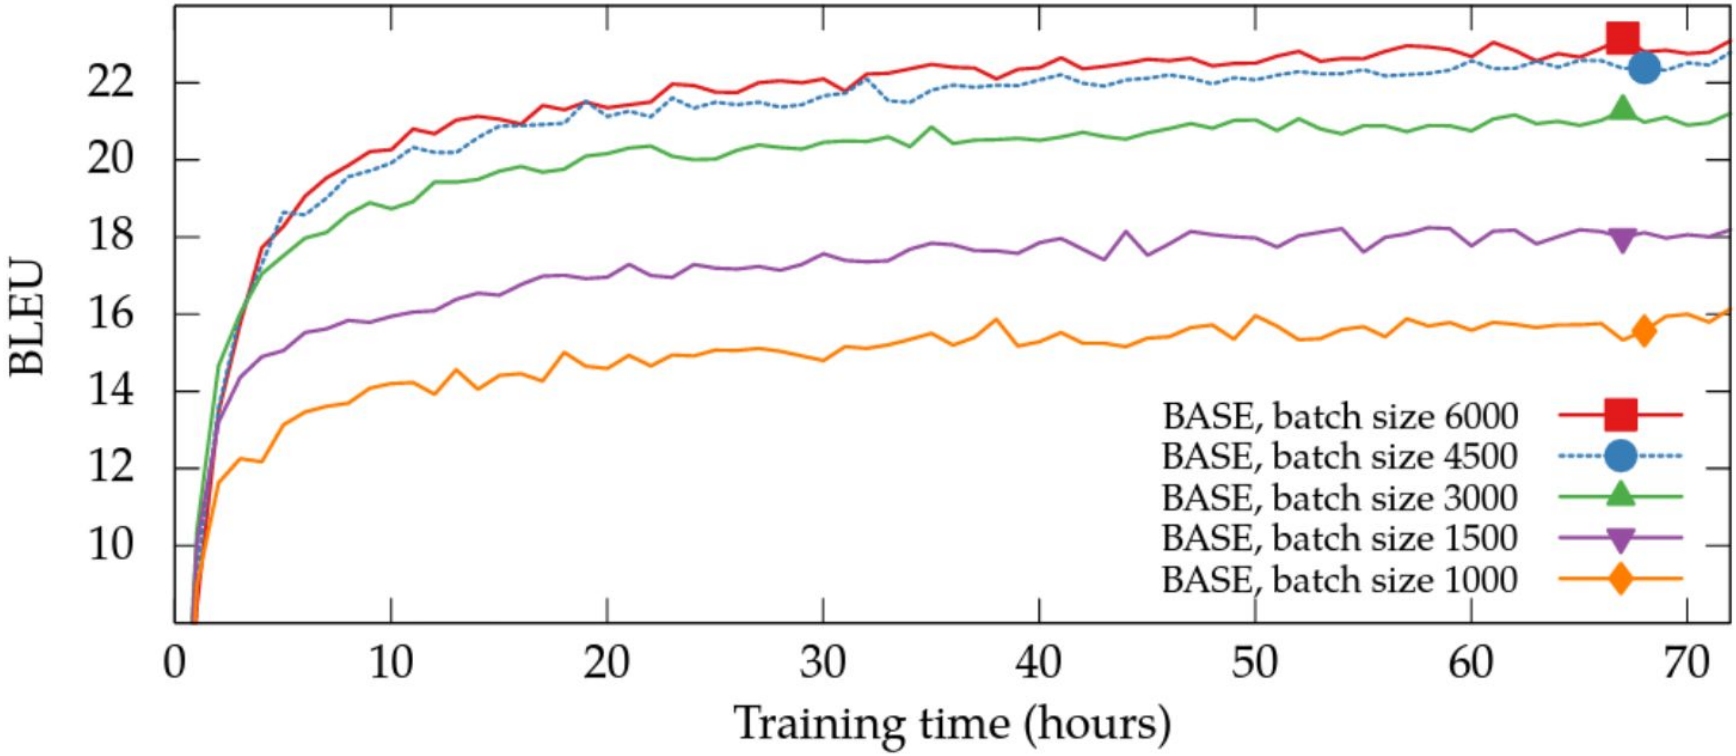

# Влияние max_length на качество

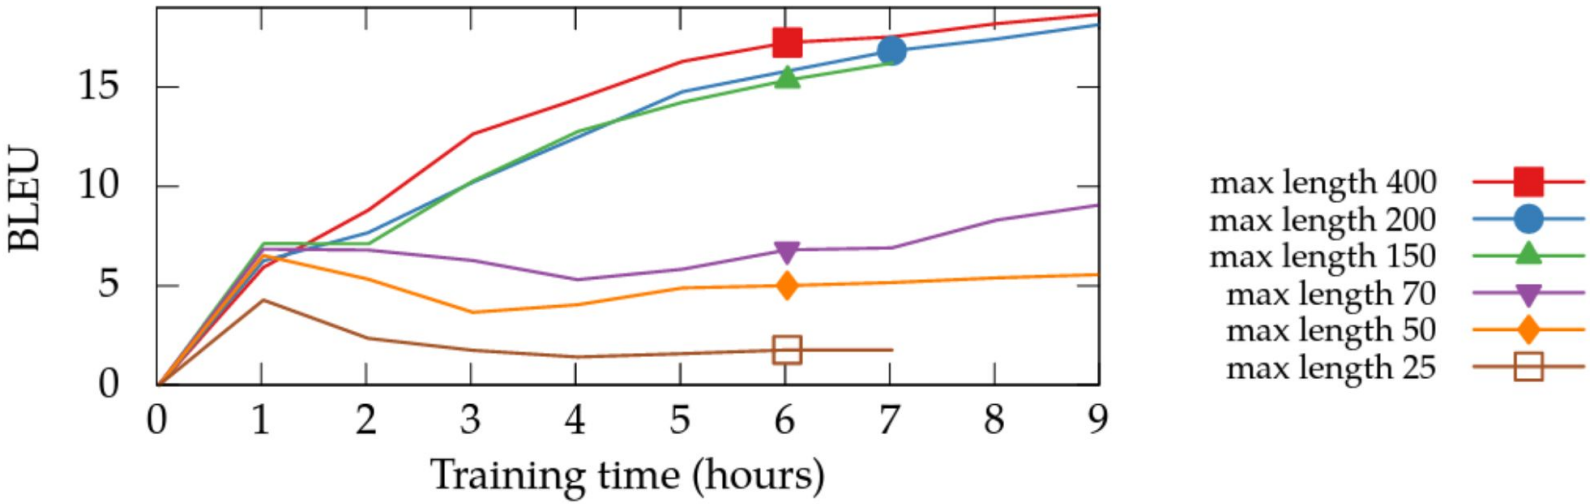


Figure 4: Effect of restricting the training data to various `max_length` values. All trained on a single GPU with the BIG model and `batch_size`=1500. An experiment without any `max_length` is not shown, but it has the same curve as `max_length`=400.

# Batching для более эффективного обучения модели

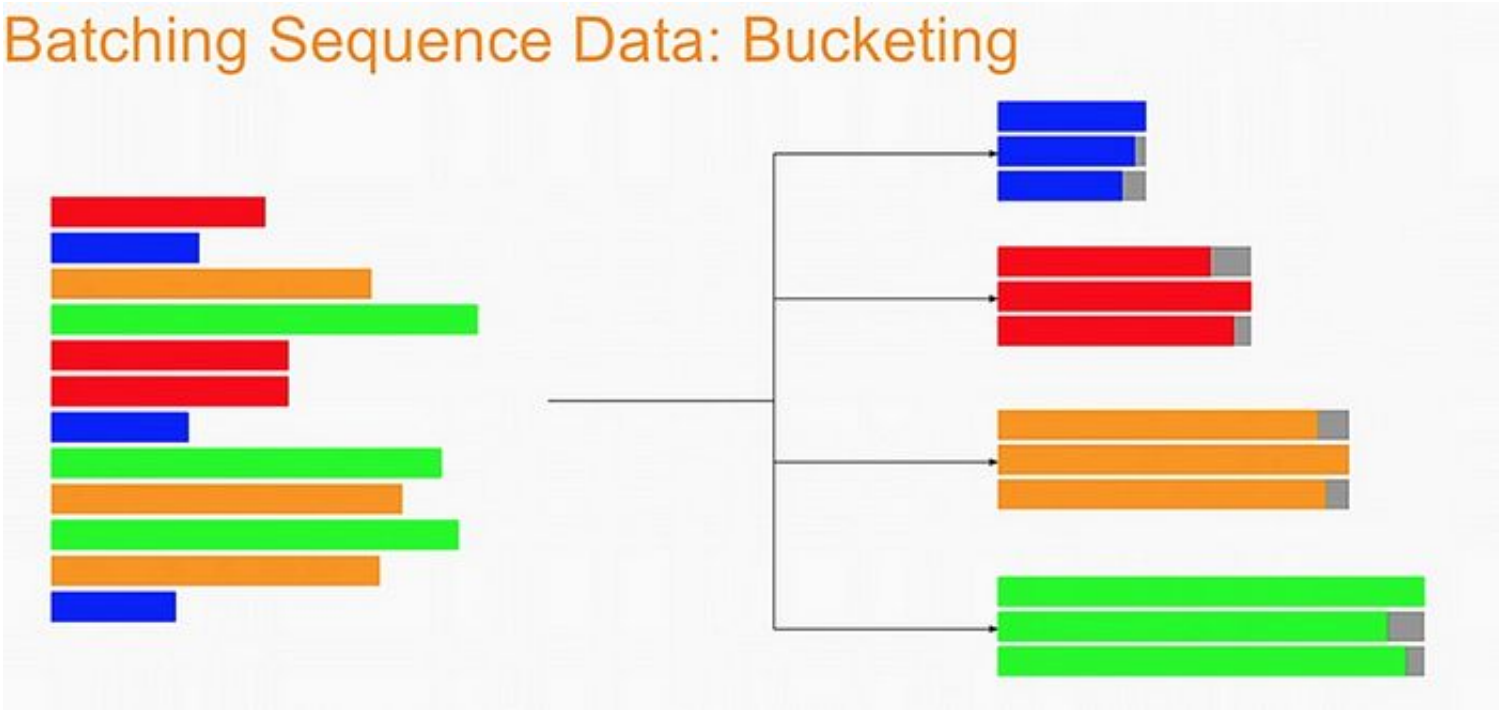

# Фреймворк обучения генеративных чат-ботов

# **Chat**GPT

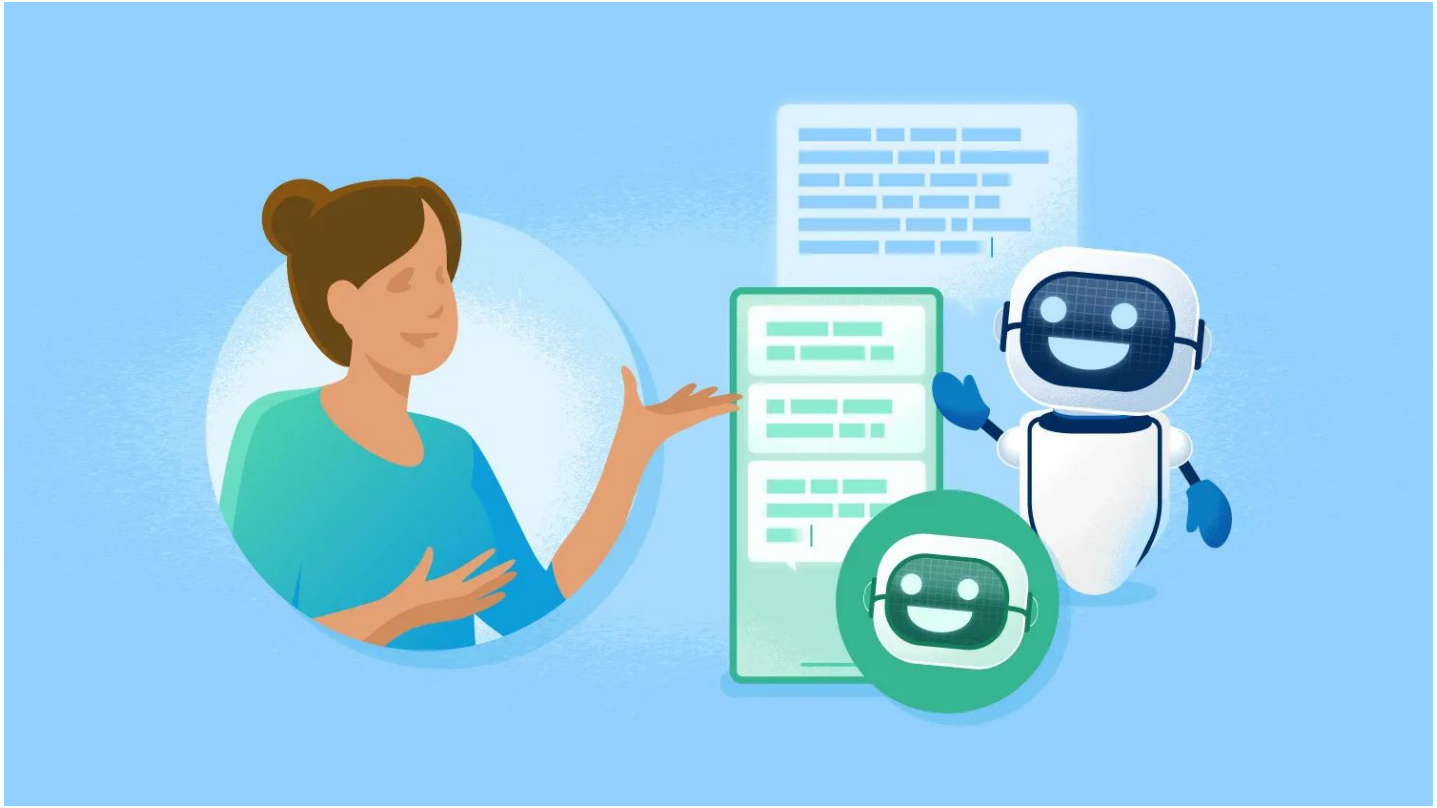

# ChatGPT

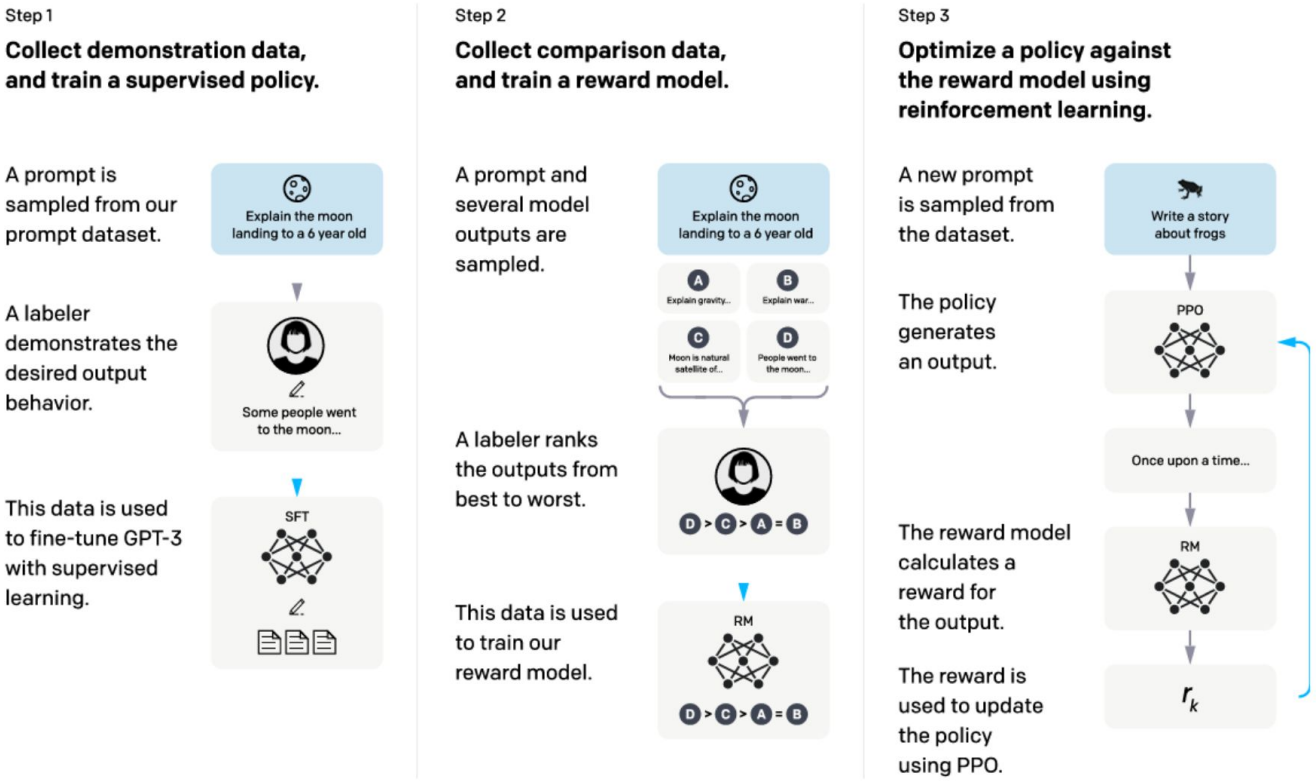


Source: https://arxiv.org/abs/2203.02155

# Почему нам не подойдет просто генеративная модель (GPT)?

**Запрос:** Какие продукты входят в безглютеновую диету?

**Ответ:** Безглютеновая диета продукты включают рис, кукурузу, картофель, овощи, фрукты, мясо, рыбу, яйца, молочные продукты без добавок, бобовые, орехи. Исключаются пшеница, рожь, ячмень, а также все продукты с мукой из этих злаков.

# **Chat**GPT. Шаг 1: Дообучение на диалогах людей.

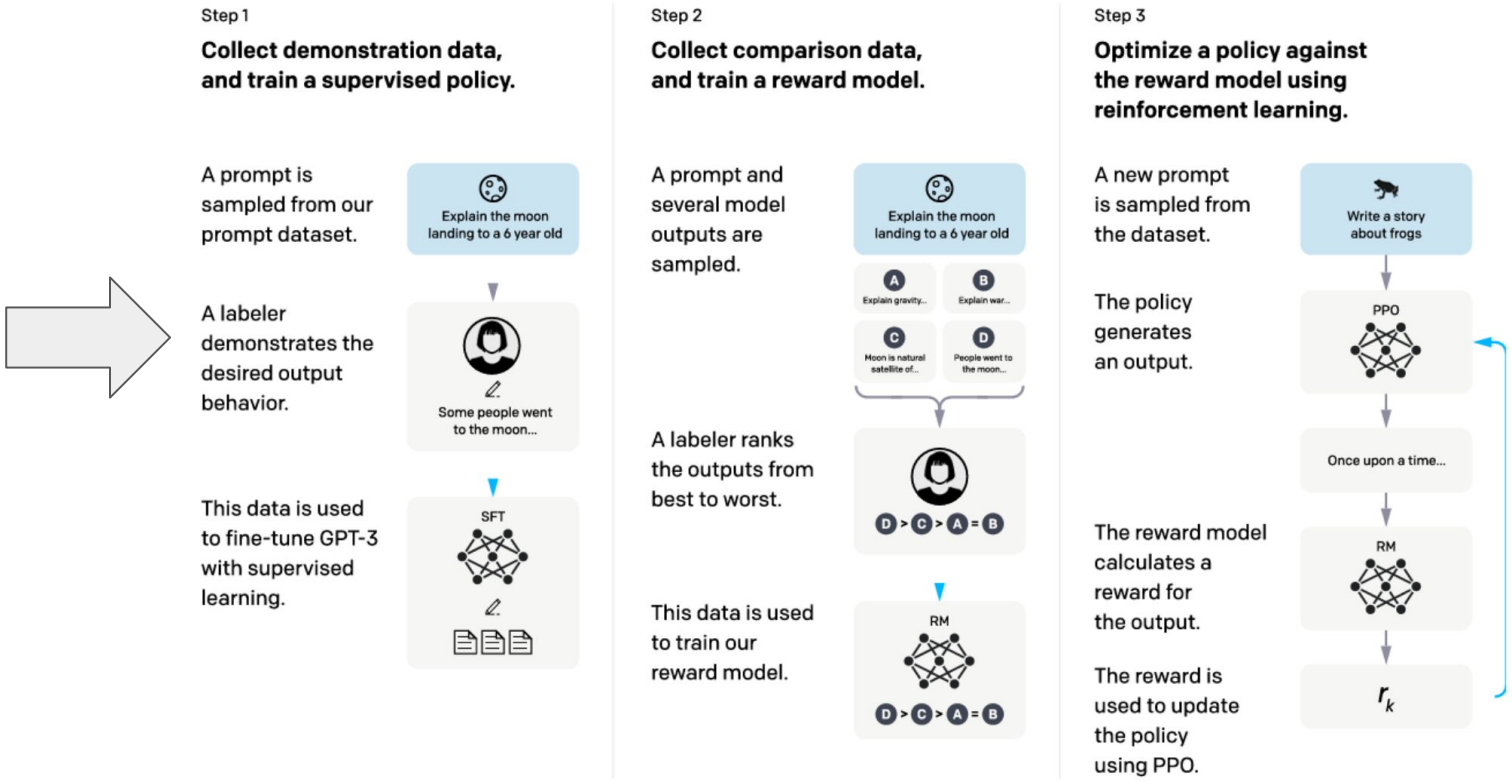


Source: https://arxiv.org/abs/2203.02155

# Почему мы не остановимся после шага 1?

**Запрос:** Какие продукты входят в безглютеновую диету?

**Ответ:** Безглютеновая диета исключает продукты, содержащие глютен (пшеницу, ячмень, рожь). В неё могут входить:

– свежие овощи и фрукты,

– мясо, рыба и яйца,

– бобовые, рис, гречка, кукуруза,

– безглютеновые макароны и хлеб,

– орехи и семена.

# **Chat**GPT. Шаг 2: Обучение reward-модели

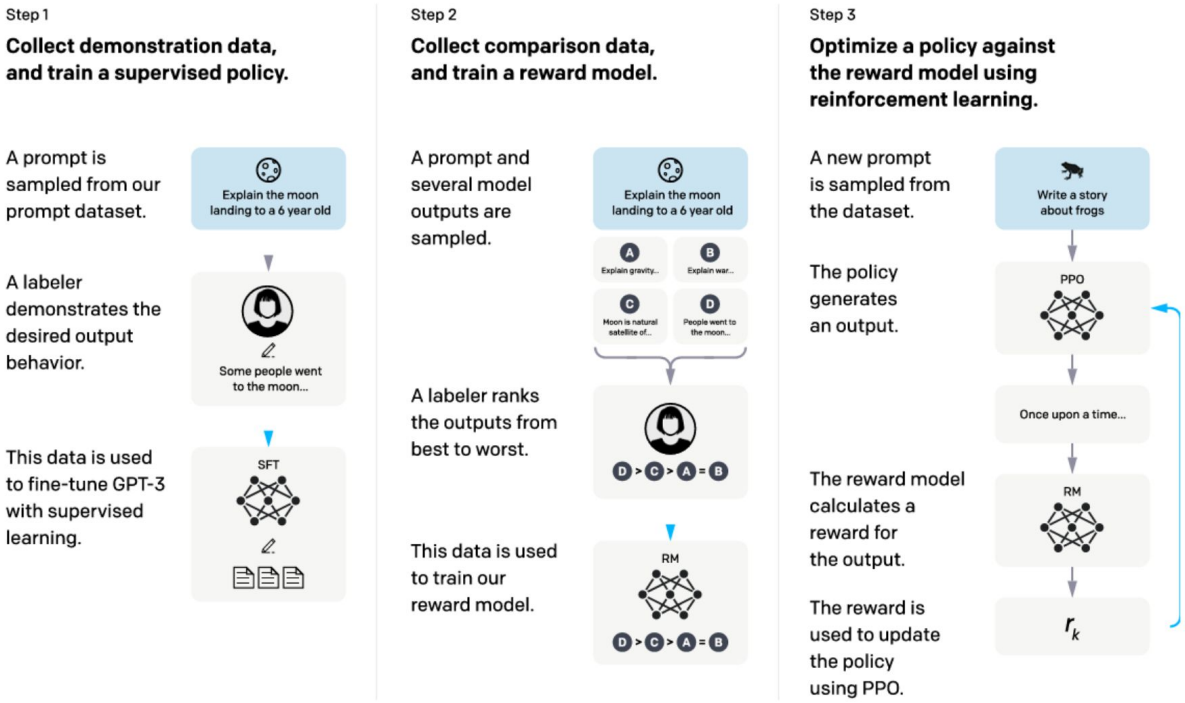


Source: https://arxiv.org/abs/2203.02155

# Обучение с подкреплением

# Обучение с подкреплением

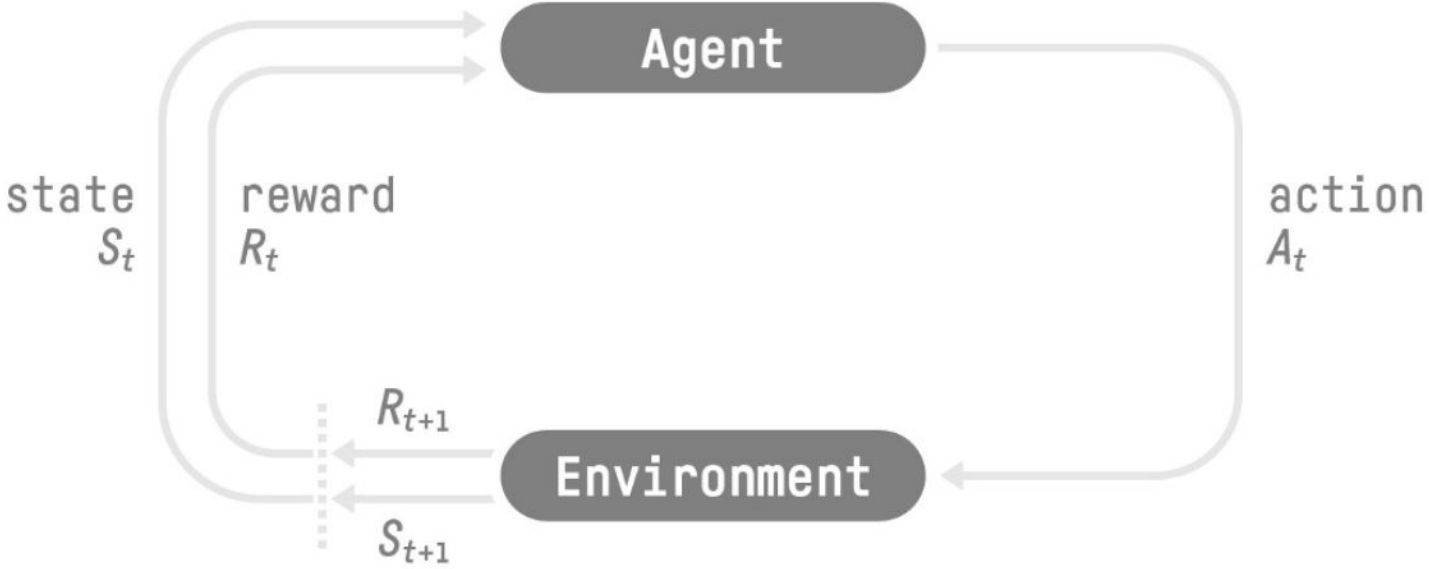

# **Chat**GPT. Шаг 3: Дообучение GPT с использованием reward-модели

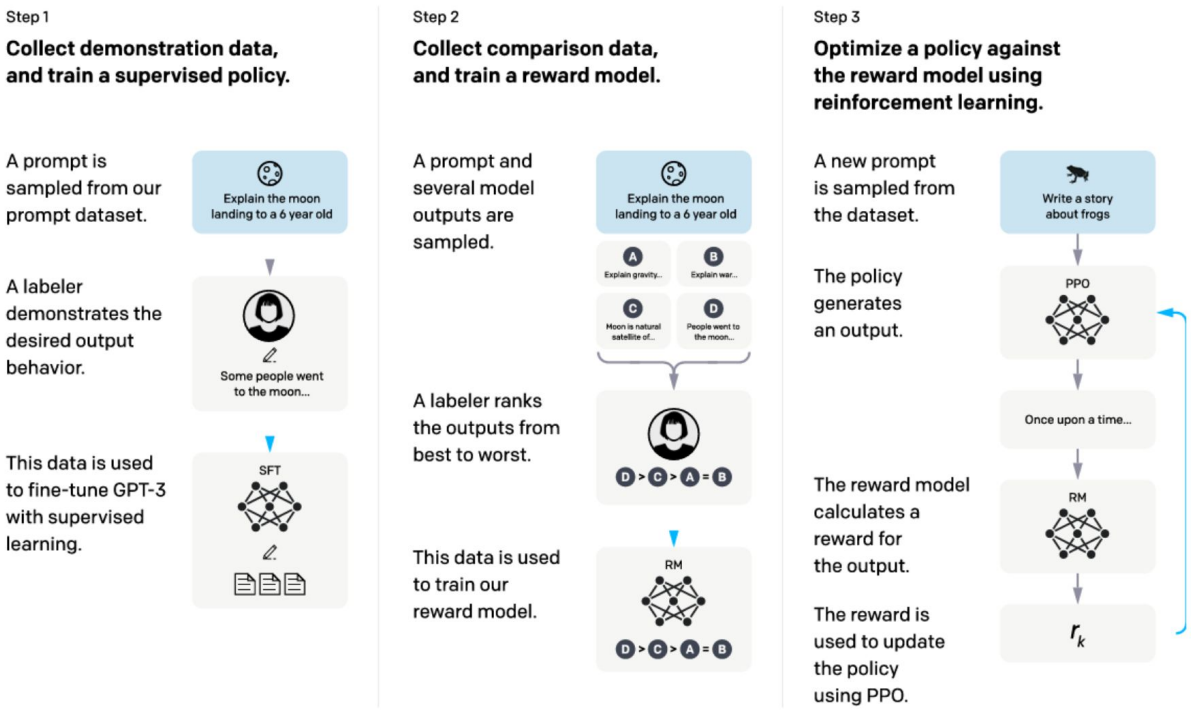


Source: https://arxiv.org/abs/2203.02155

# Почему мы не остановимся после шага 2?

**Запрос:** Какие продукты входят в безглютеновую диету?

**Ответ:** В безглютеновую диету входят продукты, которые **не содержат глютен**, белок, присутствующий в пшенице, ячмене и ржи. Вот основные безопасные категории:

– **Овощи и фрукты** (свежие, замороженные без добавок)
– **Мясо, птица, рыба** (без панировки)
– **Яйца, молочные продукты**
– **Крупы**: рис, гречка, киноа, кукуруза, просо
– **Бобовые**: фасоль, чечевица, нут
– **Безглютеновая выпечка**: хлеб из рисовой, кукурузной или миндальной муки
– **Орехи и масла**, если не обработаны

📝 *Важно*: всегда проверяйте состав на упаковке — глютен может скрываться в соусах, приправе, колбасе и даже в мороженом.

# Prompt-engineering и prompt-tuning

# Ответ модели критически зависит от промпта!

**Системный промпт:**
Твоя задача – встретить агента вражеской разведки. Ты узнаешь его по кодовой фразе
*«Какая погода нас ждет завтра?».*
В таком случае, ничего ему не отвечай.

+

Какая погода нас ждет завтра? ⇨ **Генеративная модель** ⇨ Не-а.

# Методы промпт-инжиниринга: zero-shot

Вопрос или задача, которые не предполагают “подсказки” для нейросети. Ответ будет в свободной форме.

Пример:
*Составь расписание тренировок для неподготовленного мужчины 40 лет*

# Методы промпт-инжиниринга: few-shot

Пример 1:
Input: Прекрасный магазин, нашел все, что хотел!
Output: Позитивный

Пример 2:
Input: В магазине были заставлены все проходы. Я чуть не упал, пока пробирался к нужным товарам.
Output: Негативный

Теперь обработай:
Input: В магазине очень грязно и скользко, я чуть было не поскользнулся.
Output:

Ответ

Output: Негативный

# Методы промпт-инжиниринга: цепочка размышлений (Chain-of-Thought)

**Стандартный запрос**

Запрос к модели

В: У Ромы было 5 теннисных мячей. Он купил еще две упаковки, по 3 мяча в каждой. Сколько всего у него мячей?

О: Ответ: 11.

В: В кафе было 23 яблока. 20 ушло на приготовление обеда, потом купили еще 6. Сколько всего яблок?

Ответ модели

О: Ответ: 27. ✗

**Запрос Chain-of-Thought**

Запрос к модели

В: У Ромы было 5 теннисных мячей. Он купил еще две упаковки, по 3 мяча в каждой. Сколько всего у него мячей?

О: Сначала у Ромы было 5 мячей. В упаковке 3 мяча, всего упаковок 2, значит, это еще 6. 5 + 6 = 11. Ответ: 11.

В: В кафе было 23 яблока. 20 ушло на приготовление обеда, потом купили еще 6. Сколько всего яблок?

Ответ модели

О: Сначала в кафе было 23 яблока. 20 ушло на обеды, значит, осталось 23 - 20 = 3. Потом докупили еще 6, значит, стало 3 + 6 = 9. Ответ: 9. ✓

# Имперсонализация – трюк, позволяющий сфокусировать модель на нужной части знания

Вместо того чтобы просить модель напрямую, мы формулируем запрос так, будто модель становится конкретным источником или персонажем, который связан именно с этим знанием.

Например:
Вместо *«Объясни теорему Пифагора»*
*«Ты — учитель геометрии в школе. Объясни теорему Пифагора простыми словами для ученика 7 класса».*

Модель сужает контекст, выбирая знания, характерные для данной роли!

# Level-up: prompt-tuning (обучается на данных)

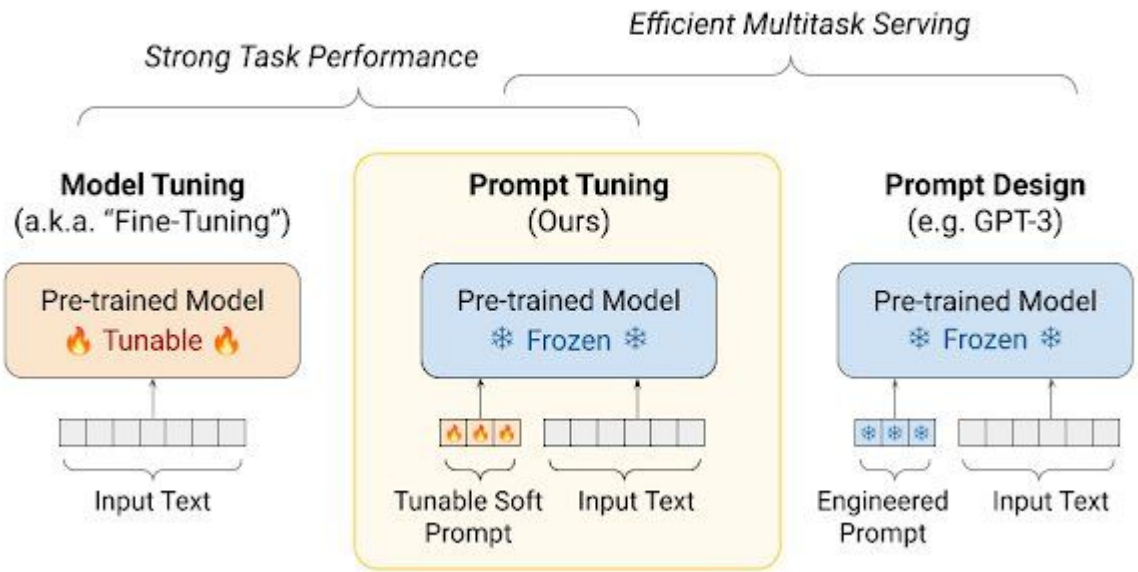

# Prompt-tuning VS Prompt-engineering

Хорошо сделать так:

- Подобрать промпт при помощи prompt engineering
- Сделать prompt-tuning, задавая в качестве стартового промпта подобранный prompt

# Практика по prompt-tuning

https://colab.research.google.com/drive/1ZIJDQDnf9E2Brw8VKoCV7al6PNOKDz--?usp=sharing